

Informe caso Vikings Fish

GESTIÓN DEL RIESGO OPERATIVO

Contenido

Resumen ejecutivo.....	2
Introducción	3
Metodología.....	3
1. Análisis exploratorio de los datos	4
1.1. Base de datos	4
1.2. Transformaciones.....	4
1.3. Estadísticos relevantes.....	4
1.4. Visualizaciones	5
2. Selección del modelo: inferencia paramétrica.....	6
2.1. Severidad.....	7
2.2. Frecuencia	8
3. Análisis de valores extremos.....	10
3.1. Block Máxima	10
3.1.1. Distribución Generalizada de Valores Extremos (GEV)	10
3.2. Peaks Over Threshold.....	11
3.2.1. Distribución de Pareto Generalizada (GPD)	11
4. Comunicación de resultados	12
Apéndice: Medición del riesgo extremo	14

Resumen ejecutivo

El presente informe pretende analizar las pérdidas de la compañía Vikings Fish Co, dedicada al cultivo de distintas especies de pescado en tierra, en concreto se pretende estudiar los efectos de los riesgos naturales en la línea de negocio más rentable, el cultivo de salmón, en cualquiera de sus tres etapas: unidad de primera alimentación, alevines y tanque de engorde.

Para ello, contamos una base de datos con 2.167 siniestros de pérdidas medidos en millones de coronas danesas y la fecha del siniestro, como solo contamos con los datos de la severidad, hemos generado unos datos a partir de los originales con información sobre la frecuencia de los siniestros.

Una vez tenemos los datasets necesarios, hemos ajustado diversas distribuciones con el objetivo de modelizar la severidad y frecuencia, de manera que la distribución que mejor se ajusta a los datos de frecuencia es una Poisson con λ igual a 0.53 y una distribución de Burr para la severidad con parámetros de forma 0.10 y 14.44, con una escala 1.08.

A continuación, hemos analizado los valores extremos de la severidad aplicando los métodos de *Block Máxima* mediante una distribución generalizada de valores extremos, agrupando los datos anualmente; y, *Peaks Over Threshold* mediante una distribución de Pareto generalizada, en este caso el umbral de corte lo hemos situado en el cuantil 99. En ambos casos el índice de forma es positivo lo que nos determina que es una distribución de cola pesada, por lo que una distribución de Frechet sería adecuada.

Por último, hemos calculado el *Value at Risk* y el *Conditional Value at Risk* para el cuantil 99, determinando que las pérdidas serían de 26 y 34 millones de coronas danesas, respectivamente.

Introducción

La empresa danesa Vikings Fish Co. dedicada al cultivo de distintas especies de pescado en tierra, con piscifactorías en 12 países, quiere estudiar los efectos de los riesgos naturales en la línea de negocio más rentable, el cultivo de salmón, en cualquiera de sus tres etapas: unidad de primera alimentación, alevines y tanque de engorde.

El nuevo director de riesgos ha recopilado una fuente externa de información, que les ayudará a desarrollar su cometido, ya que carecen de experiencia. Se trata de los datos de pérdidas incurridas por la matriz de la compañía, durante 11 años, en otras unidades de negocio.

Se encuentra un poco perdido en su cometido, pero conoce por estudios del sector que la distribución de las pérdidas podría seguir una distribución de Pareto o alguna de la familia de las Gamma.

Como no sabe cómo continuar, decide realizar algunas lecturas. Comienza ojeando el informe *Buenas prácticas para la gestión y supervisión del riesgo operativo*. Comité de Supervisión Bancaria de Basilea (2004), así como el manual *La gestión del riesgo operacional: de la teoría a su aplicación*. A. Fdez-Laviada (2007). Algo más técnico, el paper *How to model Operational Risk?* Paul Embrechts (2015).

Estas lecturas le aclaran la situación, pero le generan dudas sobre su capacidad para realizar el análisis. Dado que no dispone del tiempo suficiente para realizar el curso de riesgo operativo del Banco Central, acude a una prestigiosa consultora internacional, en la que usted trabaja, para que elaboren un informe.

El objetivo será realizar un informe que analice las pérdidas de la compañía en esta unidad de negocio. Usted es la persona encargada de elaborarlo respetando las distintas fases del proyecto de investigación.

Una vez realizado dicho informe, se extenderá al resto de las distintas unidades de negocio de la compañía (es decir, distintas especies piscícolas), dando respuestas a las siguientes cuestiones:

- ¿Cuáles son los riesgos claves del negocio por línea de actividad?
- ¿Qué controles se han establecido para gestionarlos?
- ¿Los controles establecidos son realmente efectivos?
- ¿Cómo se pueden mejorar estos controles y con ello la gestión del riesgo operativo?

Metodología

1. Análisis exploratorio de los datos
2. Selección del modelo: inferencia paramétrica
 - a. Ajuste de distribuciones
 - b. Contraste de bondad de ajuste
3. Análisis de valores extremos
 - a. Distribución Generalizada de Pareto
 - b. Distribución Generalizada de valores extremos
4. Comunicación de resultados
5. Apéndice: medición del riesgo extremo: Value at Risk (VaR)

1. Análisis exploratorio de los datos

Comenzaremos el informe con un EDA (*Exploratory Data Analysis*) con el objetivo de familiarizarnos con los datos, comprender las variables que incluyen, resúmenes estadísticos, estudio de los cuantiles, definición de la severidad y frecuencia de las pérdidas, así como un estudio de la asimetría y curtosis de los datos.

1.1. Base de datos

La base de datos disponible para realizar este informe está disponible en el paquete de R *CasDatasets*, en concreto, hemos utilizado la base de datos llamada *danishuni*, con la siguiente descripción:

El conjunto de datos univariados se recopiló en Copenhagen Reinsurance y comprende 2.167 siniestros de incendios durante el periodo de 1980 a 1990. Se han ajustado a la inflación para reflejar los valores de 1985 y se expresan en millones de coronas danesas.

Contamos con dos columnas:

- El día de la ocurrencia del siniestro
- El importe total de las pérdidas en millones de coronas danesas (DKK)

1.2. Transformaciones

Uno de los principales objetivos es modelizar la severidad y la frecuencia de los datos, es por ello, que hemos creado dos datasets en función de los datos originales:

- Frecuencia: El primer dataset cuenta con el número de siniestros ocurridos durante el periodo, para ello, hemos tenido que completar la base de datos con las fechas faltantes y rellenar los valores nulos con ceros, ya que la base original solo cuenta con las fechas de los siniestros, por lo tanto, si no tenemos la fecha es que no hay siniestro.
- Severidad¹: El siguiente dataset generado es una copia del original, ya que tenemos los datos de las pérdidas en millones de coronas danesas.

1.3. Estadísticos relevantes

Para cada dataset definido en el anterior punto, realizaremos un estudio de los estadísticos fundamentales (cuantiles, asimetría, curtosis y cuantiles).

En la Tabla 1, situada en la siguiente página, podemos observar un resumen de los principales estadísticos de la frecuencia. Como vemos existe un salto entre el tercer cuartil (75%) y el máximo (100%), es por ello, que más adelante analizaremos este rango intercuartílico, ya que estamos en un posible caso de valores extremos. En cuanto a la asimetría, tenemos un valor

¹ La severidad es otra métrica clave en el análisis cuantitativo del riesgo y se define como el porcentaje sobre la exposición en riesgo que no se espera recuperar en caso de incumplimiento.

positivo, lo que implica una asimetría positiva o a la derecha, la curtosis es elevada, lo que implica que la distribución tendrá una forma apunta (leptocúrtica).

En cuanto a la severidad, tenemos los datos representados en la Tabla 2. En este caso, vemos como la media de las pérdidas es superior a los 3 millones de coronas danesas, lo que equivaldría a unos 400.000 €, al situarse la mediana por debajo de la media, esto nos indica un indicio de asimetría positiva o a la derecha, esto se confirma al estudiar su asimetría. Aquí también observamos una distribución leptocúrtica. Por último, hay que destacar que existe un gran salto entre el tercer cuartil y el máximo, pero de manera mucho más exagerada que en los datos de frecuencia...

TABLA 1. Estadísticos de la Frecuencia

Mínimo	0.0000
Primer cuartil	0.0000
Mediana	0.0000
Media	0.5396
Tercer cuartil	1.0000
Máximo	5.0000
Asimetría	1.434283
Curtosis	5.122831

TABLA 2. Estadísticos de la Severidad

Mínimo	1.000
Primer cuartil	1.321
Mediana	1.778
Media	3.385
Tercer cuartil	2.967
Máximo	263.250
Asimetría	18.74983
Curtosis	485.6461

Tras analizar los cuartiles de ambas distribuciones, tenemos un claro ejemplo de valores extremos ya que se producen altos saltos en los datos entre el 99% y el 100%. La mayor pérdida en cuantía (severidad) fue el 15 de julio de 1980 por valor de 263 millones de DKK, mientras que el día con mayor número de pérdidas registradas fue el 3 de agosto de 1986 y el 11 de enero de 1987 con un total de 5.

1.4. Visualizaciones

Para finalizar este apartado adjuntaremos los histogramas y distribuciones kernel de ambas bases de datos:




ILUSTRACIÓN 1. HISTOGRAMA DE LA FRECUENCIA DE LAS PÉRDIDAS

En la anterior página tenemos representado el histograma de la frecuencia, como vemos, la distribución está ligeramente apuntada y posee una asimetría a la derecha tal y como habíamos comentado. Al tratarse de siniestros, es lógico que los datos se concentren cercanos al cero y cuanto más nos alejemos del origen menos datos tengamos...

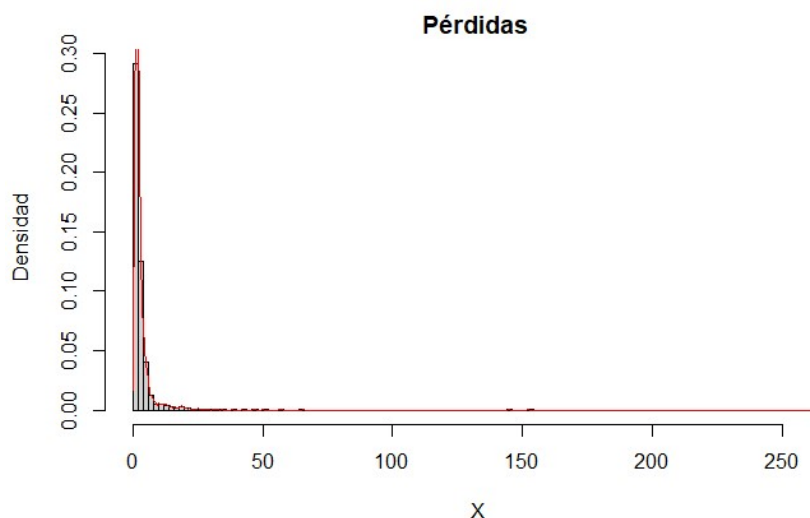


ILUSTRACIÓN 2. HISTOGRAMA Y DENSIDAD DE LA DISTRIBUCIÓN DE PÉRDIDAS (SEVERIDAD)

En la imagen superior tenemos representado el histograma y la densidad de las pérdidas en millones de coronas danesas. En este caso, la distribución está mucho más apuntada de lo normal y la asimetría positiva es mayor que en el anterior caso, tal y como hemos comentado en el resumen de estadísticos. Esto nos ayuda a entender el caso de valores extremos que tenemos.

Una vez hemos analizado los datos y contemplado la existencia de valores extremos, el siguiente punto del informe consistirá seleccionar el mejor modelo que ajuste a dichas distribuciones.

2. Selección del modelo: inferencia paramétrica

A continuación, buscaremos el mejor modelo que se ajuste a nuestros datos, para ello, lanzaremos distintas distribuciones como la ley de Pareto o la ley de Poisson con el objetivo de encontrar aquella que mejor se ajuste a los datos. Como tenemos dos tipos de datos, continuos y discretos, severidad y frecuencia, respectivamente, ajustaremos distintos tipos de modelos a cada uno de nuestros datasets.

La metodología que utilizaremos para cada dataset (recordemos que en uno tenemos la frecuencia de las pérdidas y en el otro la severidad) será la siguiente:

1. Ajuste de modelos
2. Bondad de ajuste

Para cada uno de los modelos, compararemos estimaciones por dos métodos distintos con el objetivo de encontrar el mejor ajuste posible para nuestros datos.

2.1. Severidad

Los modelos de distribuciones de probabilidad relacionados con la severidad que vamos a aplicar a la variable pérdidas son:

- La ley de Pareto
- La ley gamma
- Mixtura entre gamma y Pareto
- Distribución de Burr
- La Ley Log-Normal

Para la severidad hemos decidido enfrentar estos cinco modelos contra los datos utilizando dos métodos:

- Máxima Verosimilitud (MLE - *Maximum Likelihood Estimation*)²
- Máxima Bondad del Ajuste (MGE - *maximizing goodness-of-fit estimation*)

Tras lanzar los cinco modelos anteriores contra los datos, podemos observar en el gráfico situado más abajo, como la distribución de Burr (representada en azul oscuro) es la que mejor se ajusta a nuestros datos (representados en negro), seguida de la mixtura o la log-normal.

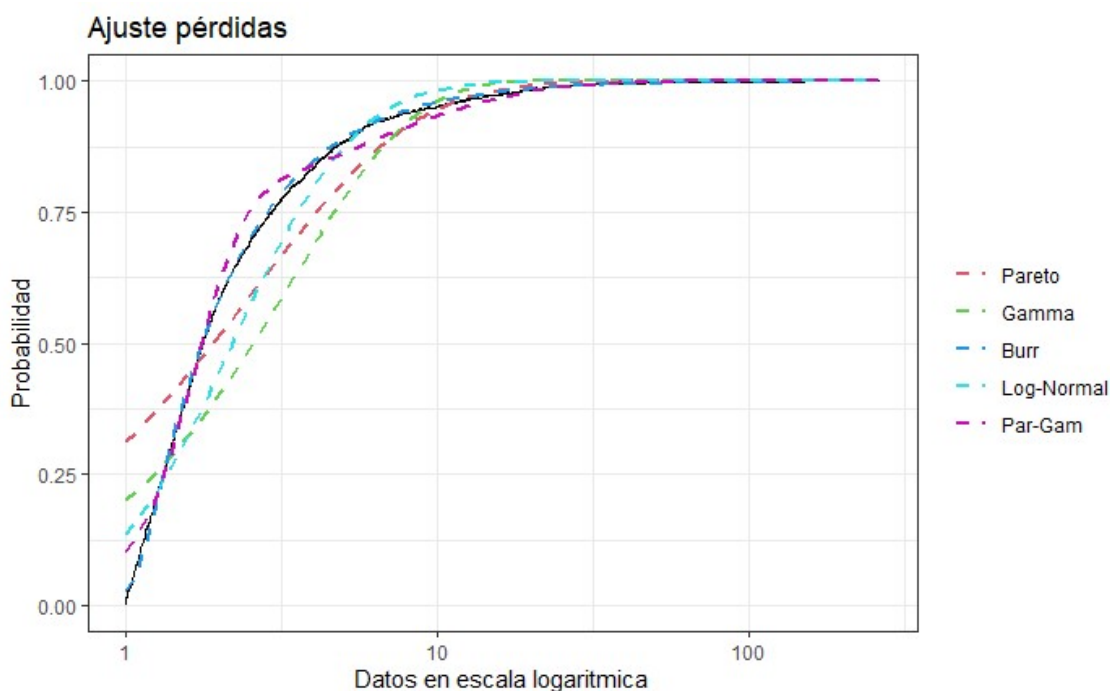


ILUSTRACIÓN 3. AJUSTE DE LAS DISTRIBUCIONES DE PÉRDIDAS (SEVERIDAD) POR MLE

Para tener una mayor certeza de lo afirmado anteriormente, hemos decidido realizar un QQ-Plot (recordemos que el objetivo de los gráficos cuantil-cuantil es demostrar cuan de parecido es una distribución a los datos) y un PP-Plot (Un gráfico P-P compara la función de distribución acumulativa empírica de un conjunto de datos con una función de distribución acumulativa teórica especificada).

² En este caso, el mejor método ha sido el MLE, es por ello, que en este informe solo comentaremos los resultados del MLE con el objetivo de sintetizar.




ILUSTRACIÓN 4. QQ-PLOT SEVERIDAD POR MLE




ILUSTRACIÓN 5. PP-PLOT SEVERIDAD POR MLE

En las ilustraciones 4 y 5, tenemos representados los QQ y PP plots, respectivamente. En ellos, es notable observar cómo la distribución de Burr, representado azul oscuro con el símbolo “+” es la distribución que mejor se ajusta a los cuantiles y a las probabilidades, es por ello, por lo que a priori podemos confirmar que la distribución que mejor se ajusta a la severidad es la de Burr. No obstante, deberemos realizar un test de bondad de ajuste sobre los modelos:

TABLA 3. BONDAD DE AJUSTE POR MLE EN LA SEVERIDAD

<i>Goodness-of-fit criteria</i>	Pareto	Gamma	Burr	Log-Normal	Par-Gam
<i>AIC</i>	9249.666	9538.191	6859.522	8119.795	7493.181
<i>BIC</i>	9261.029	9549.554	6876.565	8131.157	7521.587

Tras realizar el test de bondad de ajuste podemos afirmar las hipótesis planteadas anteriormente, es decir, el modelo que mejor se ajusta a nuestros datos es la distribución de Burr.

2.2. Frecuencia

A continuación, realizaremos lo mismo, pero para los datos de frecuencia. Los modelos de distribuciones de probabilidad relacionados con la frecuencia que vamos a aplicar a la variable son:

- La ley de Poisson
- La ley Binomial Negativa

En este caso, también utilizaremos MLE, pero no podemos ajustar el MGE porque es para variables continuas, es por ello por lo que utilizaremos el método de los momentos. Para la frecuencia, el mejor método de estimación ha sido MLE, por lo que solo comentaremos sus conclusiones...

En el gráfico de la siguiente página, podemos observar el ajuste de las distribuciones anteriores a nuestros datos, como podemos observar no podemos descartar ninguno de los modelos de manera visual, ya que ambos se ajustan bastante bien...

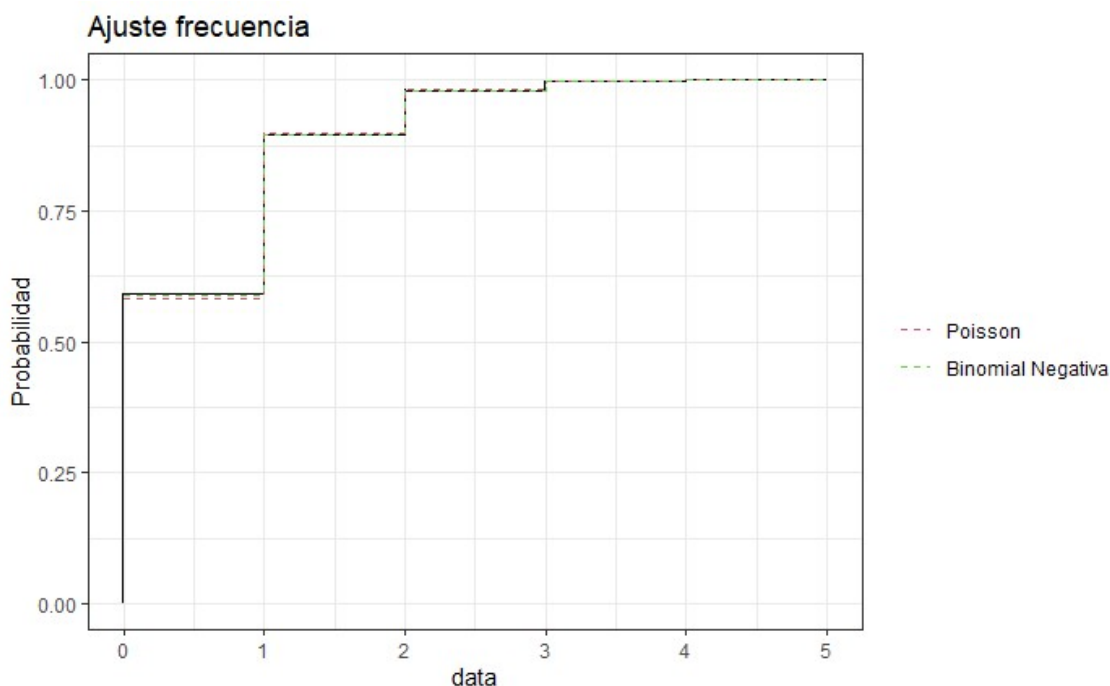


ILUSTRACIÓN 6. AJUSTE DE LAS DISTRIBUCIONES DE FRECUENCIA POR MLE

Tras realizar el test de bondad de ajuste los resultados son muy similares, por lo que cualquiera de los dos modelos es óptimo para nuestros datos. Sin embargo, daremos prioridad al criterio BIC, por lo que seleccionaremos la distribución de Poisson para ajustar la frecuencia.

TABLA 4. BONDAD DE AJUSTE POR MLE EN LA FRECUENCIA

<i>Goodness-of-fit criteria</i>	Poisson	Binomial Negativa
<i>AIC</i>	7819.697	7817.864
<i>BIC</i>	7825.995	7830.460

Durante este apartado hemos determinado que la distribución que mejor se adecúa a los datos de la severidad (pérdidas) es la distribución de Burr con los siguientes parámetros:

- *Shape 1*: 0.10
- *Shape 2*: 14.441676
- *Scale*: 1.085243

Para la frecuencia, hemos determinado que ambas eran muy similares, pero nos hemos decantado por la ley de Poisson por tener un mejor BIC, el parámetro lambda en cuestión es:

- *Lambda*: 0.5395916

Continuando con la metodología planteada al inicio de este informe, lo siguiente que realizaremos será el análisis de valores extremos.

3. Análisis de valores extremos

La Teoría de Valores Extremos (EVT de sus siglas en inglés) es la rama de la estadística que centra su estudio en los eventos asociados a las colas de la distribución (valores más altos o bajos de la variable sometida a estudio).

Utilizada para predecir las posibilidades de eventos que nunca anteriormente han ocurrido. Ayuda a entender los patrones de comportamiento de tales eventos.

Los riesgos extremos, por definición no son comunes, sin embargo, se pueden obtener resultados estadísticos significativos si se aplican los métodos de inferencia adecuados y si se interpretan los resultados cuidadosamente. La cantidad de datos de eventos extremos como es obvio no debe ser muy grande dentro de las operaciones diarias de las entidades, pero en cambio puede ocasionar un gran impacto económico dentro de la unidad de negocio.

El planteamiento será la utilización de eventos pasados para estimar el futuro.

La modelización de las colas de la distribución puede desarrollarse a través de diferentes estrategias:

- *Block Máxima*: Se basa en el ajuste de la distribución de los valores máximos o mínimos.
- *Peaks Over Threshold*: El análisis de valores extremos se realiza a partir del análisis de los valores que exceden cierto umbral.

3.1. Block Máxima

Para *Block Máxima* hemos decidido agrupar por los datos por años, de manera que el resultado es el siguiente:

TABLA 5. DATOS POR BLOCK MÁXIMA

1980	1981	1982	1983	1984	1985	1986	1987	1988	1989	1990
263.25	56.22	65.70	65.70	19.16	57.41	29.02	32.46	47.01	152.41	144.65

En la Tabla 5 tenemos representados los datos por años con sus pérdidas máximas, en este caso, la mayor pérdida se produce en 1980 por una cuantía de 263 millones de coronas danesas, durante la década de los 80 parece que las pérdidas se estabilizan, pero es a partir de 1980 cuando volvemos a tener dos valores muy extremos.

3.1.1. Distribución Generalizada de Valores Extremos (GEV)

Tras ajustar la distribución obtenemos los siguientes parámetros:

- μ (posición) = 37.79
- σ (escala) = 28.93
- ξ (forma o índice de cola) = 0.63

Al ser positivo el índice la distribución se correspondería con una Distribución de Frechet (*heavy-tail distributions*).

3.2. Peaks Over Threshold

Para la determinación del umbral, hemos estudiado los cuantiles de la severidad, localizando que a partir del cuantil 99 es cuando se produce un mayor cambio, este tiene un valor aproximado de 25 millones de coronas danesas, por lo que el umbral seleccionado en esta estrategia ha sido el cuantil 99, es decir, 25.




ILUSTRACIÓN 6. PROBABILIDADES TEÓRICAS Y EXCESOS




ILUSTRACIÓN 7. FUNCIÓN DE DISTRIBUCIÓN ACUMULADA

En las ilustraciones superiores podemos observar las probabilidades teóricas de las pérdidas y la distribución acumulada, de manera que aquellas pérdidas con menor importe tendrán una probabilidad superior de ocurrencia, mientras que la de 263 tiene la probabilidad más baja (ilustración 6).

3.2.1. Distribución de Pareto Generalizada (GPD)

Los parámetros obtenidos son:

- σ (escala) = 10.40
- ξ (forma o índice de cola) = 0.82

Esto significa que la cola de la distribución es pesada porque el índice de cola es mayor a cero.




ILUSTRACIÓN 8. QQ-PLOT GPD

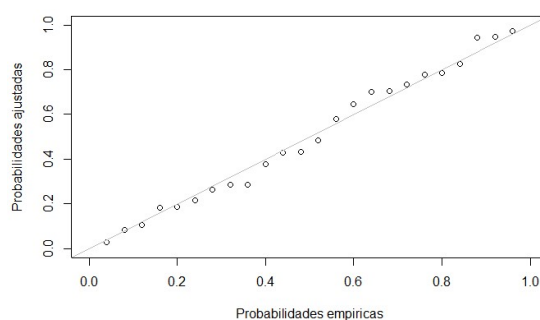


ILUSTRACIÓN 9. PP-PLOT GPD

En los gráficos superiores podemos observar como la distribución generalizada de Pareto se ajusta perfectamente a los valores menos extremos, pero en los 3 valores más extremos, recordemos que son las pérdidas de 144, 152 y 263 millones de coronas danesas, no se ajusta demasiado bien...

4. Comunicación de resultados

Al principio del presente informe nos hemos marcado unos objetivos y unas cuestiones abiertas que resolveremos durante este apartado. En concreto, comentaremos los resultados y conclusiones del análisis de pérdidas.

En primer lugar, hemos modelizado la severidad y la frecuencia de 2.167 incendios ocurridos durante el periodo comprendido entre 1980 y 1990. Tanto para la severidad como la frecuencia hemos ajustado distintas distribuciones por diversos métodos de estimación resultado siempre mejor el método de Máxima Verosimilitud (MLE). En el caso de la severidad, la distribución que mejor se ajusta a los datos en una distribución de Burr con parámetros de forma 0.10 y 14.44, con una escala 1.08. Por otro lado, hemos ajustado diversas distribuciones con el objetivo de modelizar la frecuencia, resultando la Poisson ($\lambda = 0.53$) la distribución que mejor se ajusta a nuestros datos.

Además, hemos realizado un análisis de valores extremos utilizando dos metodologías:

- *Block Máxima*: Seleccionamos los valores máximos de cada año y ajustamos una distribución generalizada de valores extremos con los siguientes parámetros:
 - Posición = 37.79
 - Escala = 28.93
 - Forma o índice de cola = 0.63
- *Peaks over Threshold*: Seleccionamos los datos por encima del cuantil 99 (aproximadamente 25 millones en pérdidas) y ajustamos una distribución generalizada de Pareto con los siguientes parámetros:
 - Escala = 10.40
 - Forma o índice de cola = 0.82

En ambos casos al tener un índice positivo nos determina que los datos tienen una cola pesada, ajustándose una distribución de Frechet o *heavy-tail distributions*.

Por último, responderemos a las cuestiones planteadas en la introducción sobre los posibles riesgos de la compañía y los controles recomendados tras la elaboración del presente informe.

Comenzaremos enumerando los posibles riesgos por cada línea de negocio ³. Encontramos riesgos por localización, ya que países como Japón o Chile pueden presentar eventos naturales que supongan un riesgo para nuestras instalaciones, como puede ser el caso de terremotos. Además, al tener diferentes localizaciones deberemos localizar a nuestros clientes, ya que el transporte de la mercancía puede ser un riesgo, un ejemplo de ello, puede ser el transporte marítimo y la paralización del tráfico por el canal de Suez. Por último, al tratarse de líneas de

³ Entendemos que cada línea de negocio son las distintas especies criadas en cada uno de esos 12 países.

negocio en distintos países podemos tener riesgo por tipo de cambio y por tipo de interés (sería interesante estudiar la posibilidad de contratar derivados).

Para estos posibles riesgos, recomendamos la implementación de los siguientes controles:

- Contratación de seguros (producción en curso, contra posibles incidentes, responsabilidades...)
- Mantenimiento preventivo y correctivo de las instalaciones para evitar posibles pérdidas causados por el paso del tiempo, así como el control de las instalaciones tras fenómenos meteorológicos.
- *Business Continuity Plan*: Tener un plan de actuación para la continuidad del negocio.

Todos estos controles serán claves a la hora de gestionar posibles crisis derivadas por los siniestros analizados en este informe. Para mejorar estos controles, lo principal es tener una manera de medirlos, para ello recomendamos a la empresa marcarse KPIs (*Key Performance Indicators*) y KRIs (*Key Risk Indicators*)⁴

⁴ Los indicadores clave de riesgo o KRI, por sus siglas en inglés (*Key Risk Indicators*), son métricas que se utilizan para determinar el potencial de un riesgo eventual y tomar medidas oportunas.

Apéndice: Medición del riesgo extremo

El concepto de Valor en riesgo (VaR), se considera la medida estándar en la medición y la gestión del riesgo de mercado; mide las pérdidas máximas estimadas en el valor de mercado de una cartera, es decir calcula una eventual pérdida extrema para un determinado periodo de tiempo utilizando una media de la volatilidad de los últimos “n” días.

La pérdida extrema es el cuantil 95, 97, 99... $(1-\alpha)$ % de la distribución.

Para este apéndice hemos realizado dos ejercicios:

1. Hemos calculado las pérdidas empleando una distribución generalizada de Pareto utilizando el cuantil 99 (recordemos que es el mismo umbral seleccionado en el apartado 3) con VaR y CVaR.
2. Simulamos un caso en el cual rendimiento anual de las acciones de Vikings Fish se distribuye con una media de 0.025 y una desviación estándar de 0.10. Un inversor decide comprar 50.000 KDD:
 - a. Determinar el VaR 0.95 y 0.99 a un año
 - b. Determinar el VaR 0.95 y 0.99 a un año
 - c. Representación gráfica

Cálculo de las pérdidas mediante GPD

Para el cálculo de pérdidas hemos establecido el mismo umbral que en el apartado 3.2, es decir, aproximadamente pérdidas superiores a 25 millones de coronas danesas, con ello hemos establecido los siguientes resultados:

- *Value at Risk* (VaR): 26. 11 millones de coronas danesas
- *Conditional Value at Risk* (CVaR): 34 millones de coronas danesas

De manera que la pérdida que estimamos dentro de un horizonte determinado y con el nivel de confianza mencionado la pérdida es de 26 millones de coronas, mientras que las pérdidas esperadas considerando que las pérdidas son mayores que el VaR, es decir, las calculadas con el CVaR son de 34 millones de coronas danesas.

Simulación inversor de Vikings Fish

De forma adicional, hemos planteado un caso en el cual inversor está dispuesto a adquirir 50.000 KDD de la empresa Vikings Fish. El rendimiento anual de las acciones se distribuye con una media de 0.025 y una desviación estándar de 0.10.

El objetivo será determinar el *Value at Risk* (VaR) y el *Conditional Value at Risk* (CVaR) del 95 y 99% a un año, así como su representación gráfica.

Tras el cálculo obtenemos los siguientes resultados:

Tabla 6. VaR y CVaR	95 %	99 %
<i>Value at Risk</i> (VaR)	6974.268	10381.739
<i>Conditional Value at Risk</i> (CVaR)	9063.564	12076.071

En la Tabla 6 tenemos el cálculo del VaR y el CVaR y en la Ilustración 10 tenemos sus curvas representadas según el parámetro Alpha. Gracias al gráfico inferior, podemos observar como el *Conditional Value at Risk* representado por la línea discontinua en rojo, es mayor que el VaR para un mismo Alpha, esto es porque el CVaR es el resultado de tomar el promedio ponderado de las observaciones de las cuales la pérdida excede el VaR. Por lo tanto, el CVaR supera la estimación del VaR, ya que puede cuantificar situaciones más arriesgadas, complementando así la información que brinda el VaR. Es por ello por lo que recomendamos trabajar con el CVaR.




ILUSTRACIÓN 10. PLOT VaR y CVaR PARA EL CASO SIMULADO